

MAVRA

面向数据智能体的 共享指标定义有效性维护

Keeping Shared Metric Definitions Valid for Data Agents

2026 / 10 / 12 · 论文进展汇报 · SIGMOD 2027

问题与动机 → 有效性模型 → 维护与执行 → 实验与讨论

数据库必须替智能体记住：学到的定义为什么成立

把前提变成条件

从结构化定义推出粒度、连接多重性、时间角色与覆盖；证据随数据版本保存。

73% / 57%

已建模破坏下：MAVRA / 轨迹检索
智能体最终答案正确率

让证据约束使用

声明的修订只在条件成立的快照上执行；依赖版本一致才复用结论。

0 / 11,297

并发写入下：绑定快照执行
在条件不成立的数据上作答的次数

失效后有界修复

修复必须不丢业务键、结构上唯一并通过回归；否则撤下定义。

64.47 → 37.68

固定库会话：不共享 → MAVRA
平均完成秒数

SQL 照常执行，退货金额却被算了两次

Agent A 学到定义

一笔退货 = 一条完成记录
小票—商品键唯一
SQL: SUM(sr_return_amt)

ETL 追加状态流水

同一退货又多一条申请行
键不再唯一
表名、列名、类型均不变

Agent B 复用共享 SQL

学习者的会话已经结束
新会话没有基准真值
执行成功也看不出重复计数

6,588,699.86

共享 SQL 返回的单期金额

3,294,349.93

该期间实际的已完成退货金额

共享保存了业务知识，也让一次过期观测传播给之后的每个智能体。

使用者变成智能体后，三件事发生了变化

前提从设计变成观测

智能体在当前快照查明粒度和连接。

观测通常只留在轨迹中；之后的纯数据更新可能打破它。

生产者与消费者脱钩

定义在学习会话结束后继续存在，并服务全新的会话。

一次过期的证据会影响所有复用者。

消费者看不出破坏

表结构未变，SQL 不报错，结果仍像一个合理数字。

消费者既没见过原证据，也没有真值。

需要持续维护“定义—条件—证据”的联系，并让证据决定每次使用是否有效。

智能体反复获取的是知识，探查 SQL 写法却不同

观察	应用负载： Redset	智能体： 100 个全新会话
复用对象	稳定的查询模板	表结构、粒度、连接等事实
重复程度	半数集群 80% 查询完全重复	93% 的查找重复此前事实
SQL 探查	34% 读查询由结果缓存回答	38% 重复事实；逐字重复为 0
探索与验证	知识预先写在应用代码里	68% 调用用于探索； 16% 会话查键唯一性
错误方式	—	32 个错误答案全部来自成功执行的 SQL

共享能减少重复探索；支撑共享定义的事实仍需在更新后重验。

保持共享口径正确，需要回答三个问题

■ 该检查什么？

定义依赖的数据性质不在 SQL 或表结构中明示。

从结构化实现推导四类可执行条件。

命题 1：业务前提下的充分性。

■ 何时可以使用？

刚通过的检查只描述一个快照；随后可能有写入提交。

查询与检查读取同一快照。

引理 1：事务性版本相同才复用。

■ 失效后怎么办？


过滤可恢复每键一行，却选错业务总体。

只发布唯一且经过回归的替代修订。

算法 1：有界搜索与安全撤下。

有效性证据成为可维护的状态，并直接约束共享定义的使用。

中间层贯通准入、维护和执行



find_metric 返回有效修订； run_sql 在使用时核对，并在绑定快照模式下保证条件成立。

四类条件把数据前提变成可执行的证据

修订 $m^r = (B, I, C, E, r) = \text{业务含义} + \text{结构化实现} + \text{条件} + \text{证据} + \text{修订号}$

条件	检查的性质
过滤后键唯一性	每个业务键在持久过滤后最多一行
连接多重性	允许的连接方向不会把事实行放大
时间角色	事实按声明的日期关系归入期间
日期覆盖	匹配不到日期维度的比例不超过准入时

命题 1：充分性

业务事件与过滤后的键一一对应，且度量表达式给出事件度量值时：

四类条件成立 $\Rightarrow$ 每个事件在其期间恰好贡献一次；遗漏受覆盖条件约束。

保证依赖业务前提；取值单位变化、等价总体和合法但错误的日期键需要额外语义证据。

更新触及哪些条件，就维护哪些证据

一次数据更新

store_returns 变化

未触及表的条件保留
受影响条件进入重验



定义级重验证

8 个受影响定义

重查全部条件
共 19 次检查

按条件复用

3 个不同的受影响条件


每个版本只检查一次
所有相关定义共享结论

结论索引 = (条件身份 , 依赖表版本)
并发遇到同一检查时共享正在执行的工作

TPC-DS 的 99 个模板自然形成共享：
175 个定义 / 65 个不同条件 / 每条件 8.6 个实例

重验工作的单位是不同条件；通用版本缓存也能利用这种共享。

每次声明使用，绑定到查询自己的快照



引理 1：结论复用

条件读到的每张依赖表事务性版本都相同 $\Rightarrow$ 条件结论可复用。
写入与版本增量在同一事务中提交、在同一快照中可见。

**默认 DML 统计异步更新，
相同统计值不能替代事务性版本。**

保证作用于声明的修订及其条件；启用绑定快照模式后，检查和查询读取同一数据状态。

失效后：唯一、不丢键、过回归才发布修复

恢复结构

过滤后每键一行
且保留全部业务键



候选唯一

没有候选或多个候选
都撤下定义



通过回归

G3-G5 重新准入
G8 与学习参照比较

状态流水：一个完成状态过滤

恢复粒度且不丢键，再用学习题检验修复后的数值。

备份副本：两个总体都每键一行

结构无法决定业务真相；候选不唯一时保持不可用。

发布新修订需要三道关；回归参照的分辨力决定自动修复能覆盖多少变化。

固定定义验证机制，完整会话验证任务收益

问题	比较方式	规模 / 证据
Q1 更新后是否正确	同一库配对回放	15 个库 / 97 个定义 / 11 种变化
Q2 并发写入时有效	执行前检查 vs 绑定快照	确定性交错 + 四组随机并发设置
Q3 何时修复或撤下	回归参照 / 唯一性 / 等待	配对题 + 备份副本反例
Q4 维护工作量	定义级 / 通用缓存 / 条件级	100 万– 1600 万行； 8–32 个脚本智能体
Q5 对智能体的作用	完整学习与使用流程	9 方法 × 3 次独立运行； 2586 道计分题
Q5 完整会话耗时	3 个固定库 × 4 种方法	216 个全新会话；每种方法 54 个

机制层覆盖合成数据与真实 TPC-DS SF1 ；端到端主实验使用 DeepSeek V4.1 Flash 。

Q1：维护后的定义在已建模变化下零错误答案

方法	答对	答错	必要不可用	保守不可用
只看结构	784	746	0	0
表级测试（dbt 式）	631	101	645	153
定义级重验	973	101	345	111
定义级 + 版本缓存	973	101	345	111
MAVRA	973	101	345	111

全表包含单位变化：各重验证方法的 101 个错误均来自这个取值语义对照。
表级测试隔离破坏；MAVRA 多答对 342 题，来自修复或定义自带过滤。

0 vs 645

已建模变化下的错误答案
MAVRA vs 只看结构

100.0%

条件级、定义级、通用缓存
逐题结果一致

配对回放隔离了学习差异：维护方式改变工作量，不改变这些题的答案。

Q1：真实 TPC-DS SF1 上重复同一配对设计

- dsdgen SF1：约 290 万行门店销售，24 张表。
- 99 个官方模板导出 93 个可表达定义；91 个通过准入。
- 相同的 11 类注入变化；状态流水、版本化更正、维表拉链可修复。
- 重复装载、日期键改写、备份副本下撤下定义。

0

MAVRA 已建模变化下
错误答案

437

只看结构
错误答案

279

经修复答对的题次
每种方法合计 981 道计分题

定义库来自官方模板；变化仍由实验注入，单位语义变化仍超出四类条件。

Q2：同快照执行消除了条件违规作答

3.8–4.6%

执行前检查：未通知写入下
在条件违规数据上作答的使用


0 / 11,297

绑定快照：随机并发合计
在条件违规数据上作答的使用

读者 / 写者代价	观测结果
读者中位延迟	26–29 ms ； 两种模式相同
单写者：相对无触发器的吞吐	0.70×
32 写者： 16 分片 / 不分片吞吐	0.97× / 0.36×

事务性版本把复用结论与快照绑定；写者吞吐代价取决于更新粒度和计数分片。


Q4：共享条件减少维护，通用缓存也得到节省



- 定义级随定义数增长：63.6 → 227.0 秒。
- 19 个定义：MAVRA 为定义级的 14.0%；通用缓存 16.7%。
- 零共享对照：所有方法为定义级的 95–102%。
- 100 万–1600 万行规模实验：比例保持在 12.0–13.0%。

核心贡献是条件、使用保证和修复规则；结论复用的节省可由通用版本缓存得到。

Q5：共享提高准确率，维护在破坏性变化下起作用



- 共享本身：32% → 75%；维护后 81%。
- 已建模破坏：73% vs 57%；预定差 +16 个百分点（95% 区间 14-18）。
- 让检索者自行验证：63%；MAVRA 仍领先。
- 改用智能体学习 SQL 作修复参照：74%。

备份副本下检索 72% vs MAVRA 61%：安全撤下会放弃部分仍正确的知识。

新增会话证据：共享定义减少任务时间和 token

方法	正确 / 54	平均完成 s	LLM 调用 / 题	输入 token/ 尝试
不共享定义	16/54	64.47	5.43	16,329
定义级重验	54/54	32.97	3.76	9,227
通用版本缓存	54/54	31.97	3.74	9,137
MAVRA	54/54	37.68	3.83	9,689


-40.7%

3 个固定库 × 4 种方法 × 18 个会话 = 216
覆盖首次、热复用、正常追加、破坏后首用和突发

MAVRA 相对不共享
每次尝试的输入 token

完整延迟结果：更新后首用更快，突发仍有模型长尾

平均完整会话完成时间（秒）



数据库工作量减少

MAVRA 比通用缓存少 25.3% 的 DB 查询时间。

整体延迟优势尚未建立

全矩阵平均 37.68 vs 31.97 s。
一次 356.23 s 长尾中，LLM 接口占 338.45 s。

测量包括 LLM、工具与排队；数据库工作量减少与完整会话加速需分别报告。

业务定义相同、正确率相同时，共享仍减少探索

方法	正确 / 54	结构查找 / 题	SQL 探查 / 题	平均完成 s
隔离探索	54/54	3.48	0.20	13.37
冻结共享	54/54	3.13	0.19	13.46
逐步积累共享	54/54	2.52	0.06	9.45
轨迹检索	54/54	3.31	0.17	11.63

-27.7%

积累共享相对隔离
每题结构查找次数

-72.7%

积累共享相对隔离
每题 SQL 探查次数

画像、连接路径和定义共同复用
消费者完成时间不含生产者学习成本

讨论：保证范围与下一步扩展

使用保证

声明修订 + 绑定快照模式：条件在所读数据上成立。

未声明使用不受此契约约束；自写 SQL 仍可能偏离规范计算。

语义与修复

业务证据提供含义。结构条件不能识别单位变化或等价总体。

下一步：取值条件、去重、日期键重映射。

评估与推广

机制层：合成数据 + TPC-DS SF1。端到端：一个模型、3 次运行。

下一步：真实更新历史、更多模型与业务库。

此前答案中 25.7% 未声明定义；声明正确修订后仍有 1.3% 因 SQL 偏离而答错。

让共享知识在变化的数据上继续成立

- ① 定义推出条件：粒度、连接、时间角色、覆盖
- ② 证据约束使用：按版本复用，在查询自身快照验证
- ③ 失效有界修复：不丢键、唯一、过回归，否则撤下
- ④ 同时衡量：正确性、维护工作量和完整任务开销

共享使智能体少探索；维护使已建模的数据破坏得到发现。

各类方法分别覆盖生命周期的哪些环节

方法	正常更新	条件破坏后	使用时保证	维护单位
轨迹检索	复用 SQL	依赖智能体自行发现	不绑定条件	检索的成功轨迹
只看结构	保留	结构未变时漏检	结构 / 修订核对	结构指纹
表级测试（dbt 式）	保留	隔离相关表上的定义	执行前的测试	按表声明的测试
写入即撤销	撤下并重学	撤下并重学	执行前核对	每次写入
定义级 + 版本缓存	保留	同样的修复与回归	执行前检查	缓存检查 SQL
MAVRA	保留	有界修复或撤下	可绑定同一快照	变化触及的不同条件

共享、验证和缓存构成基础；本文研究指标定义的有效性生命周期。

修复参照决定自动化范围，唯一性挡住歧义

同一批配对题	判题学习查询参照	智能体学习 SQL 参照
1,470 道题：答对	933	780
新增错误	—	0 （差别全部转为不可用）
端到端：已建模破坏正确率	73%	74%

反例：追加备份副本

不要求候选唯一时可发布错误修复；要求唯一时两种参照均撤下。

修复期间等待

同时到达的不可用从 63 降为 0；请求共享已有维护结果。

G8 只有在变化触及学习期间且参照反映区分列时，才提供额外分辨力。

本次更新对应论文的哪些变化

论文变化	汇报处理	对应页
摘要与引言强化中心主张	新会话复用 + 三个变化 + 持续有效性证据	2-6
固定库完整会话证据进入正文	正确率、时间、调用和 token ； 并列报告缓存基线	18-19
相同业务定义下的探索开销	四组同为 54/54 ； 结构查找、 SQL 探查和时间	20
模型、命题、引理与有界修复	保留三项方法贡献，配套机制层证据	8-16
讨论和研究边界	声明使用、取值语义、修复歧义与真实更新历史	21 、 24

论文中的主张、证据口径与汇报一致；补充实验按其实际支持范围呈现。