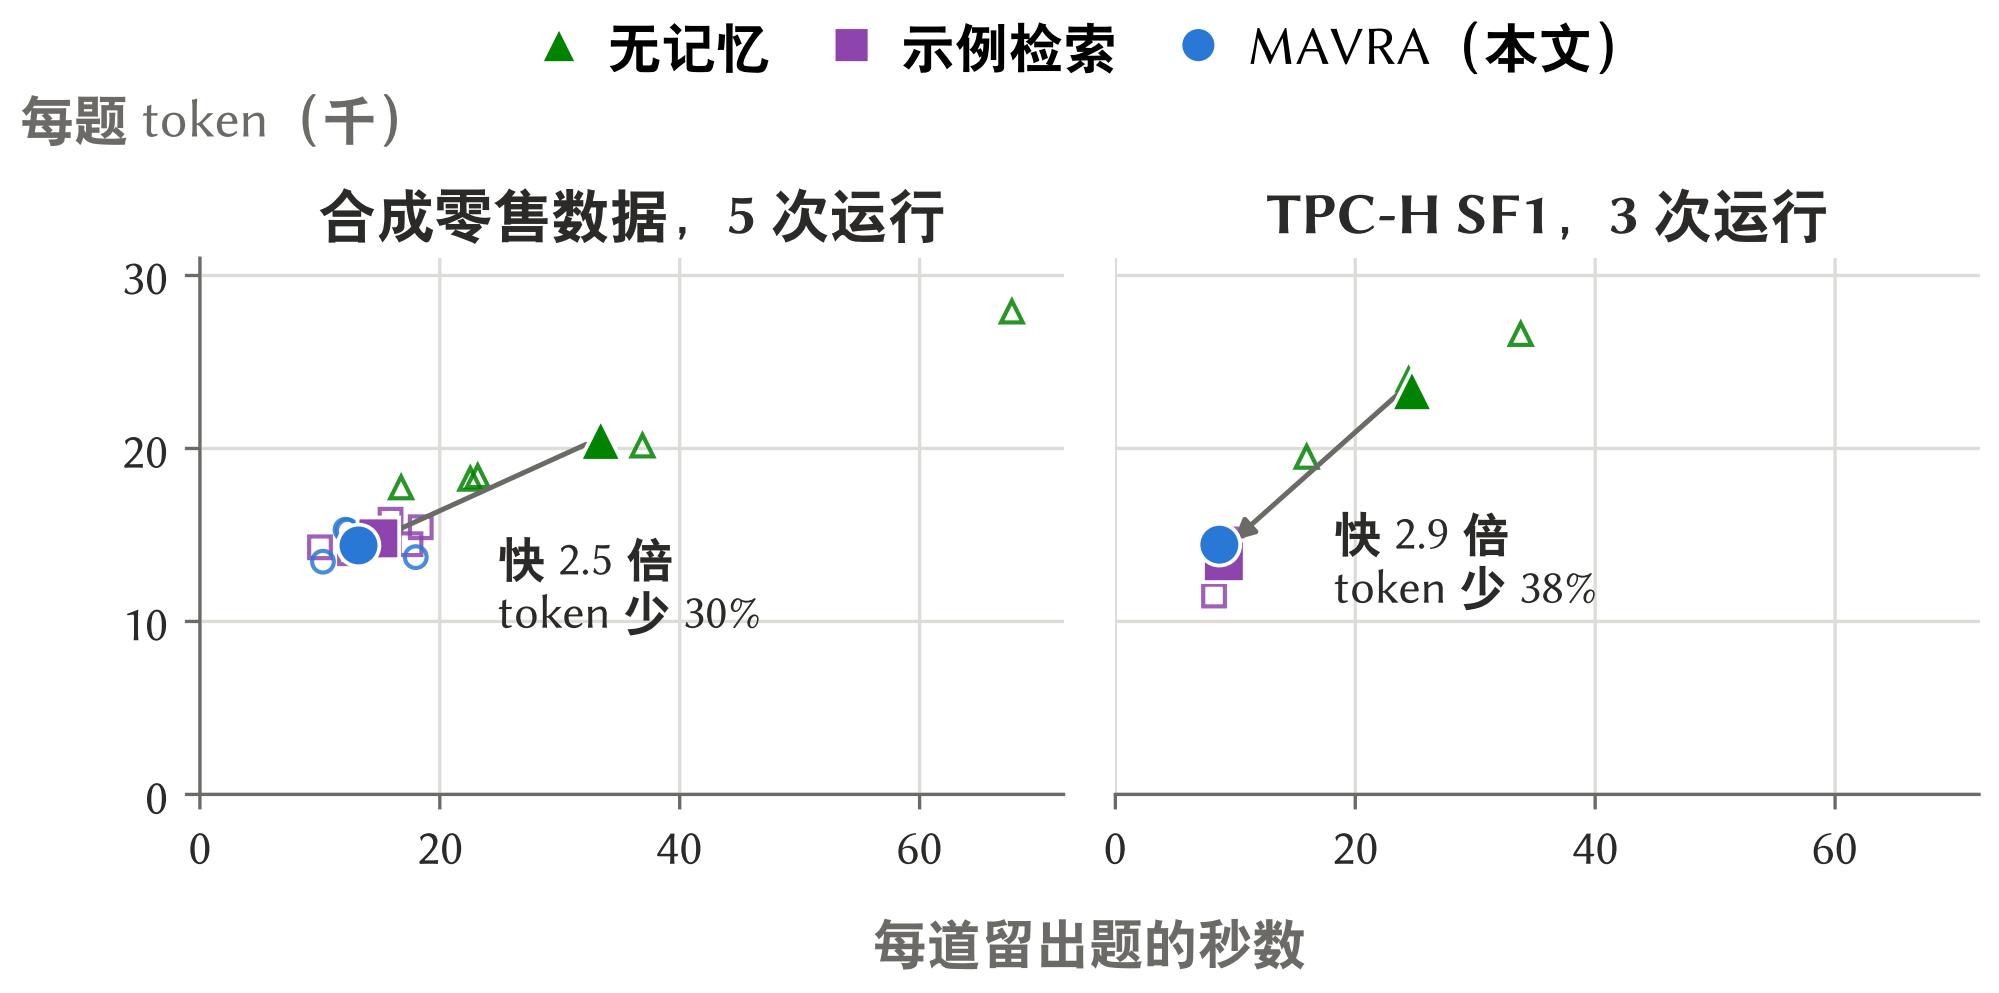
无记忆
示例检索
MAVRA（本文）
每题 token（千）
合成零售数据，5 次运行
TPC-H SF1，3 次运行
30
20
10
0
0
20
40
60
快 2.5 倍
token 少 30%
快 2.9 倍
token 少 38%
每道留出题的秒数